

---

# 「감정 기반 사용자 맞춤형 영화 추천 시스템」

---

최종 보고서

2025. 06. 12

이 영 준, 김 성 민

# 캡스톤디자인 최종보고서

구 분      단 독 ☐      공 동 ☒ ( 2 )인

성 명      이영준, 김성민

작 품 제 목      감 정 기 반 사 용 자 맞 춤 형 영 화 추 천 시 스 템

작 품 개 요      사용자가 현재 느끼고 있는 감정을 입력받고, 해당 감정과 연관성이 높은 영화를 추천해주는 감정 기반 영화 추천 시스템을 개발하는 프로젝트입니다. Amazon의 영화 리뷰 데이터를 활용하여 텍스트로부터 ‘즐거움, 슬픔, 분노, 긴장, 설렘, 편안함’ 6가지의 감정 라벨을 추출하고, 이를 기반으로 개인화된 영화 추천을 제공합니다. 본 시스템의 목적은 사용자 만족도를 극대화하고, 영화 추천의 질적 향상을 이루는 데에 있습니다.

보 완 내 용  
요 약      중간보고서에서 기술했던 감정 편향 현상을 완화하기 위해 여러 가지 샘플링 기법을 조사하였으나, 과적합 위험, 데이터 신뢰성 하락, 데이터 손실 등의 단점이 존재하여 편향이 일어난 ‘즐거움’ 감정 세분화를 진행하여 부분적으로 해결하였습니다. 또한 딥러닝 NCF 모델을 활용하여 시스템을 구현하였으며 성능을 높이는 데 많은 시간을 투자했습니다.

위와 같은 내용으로 2025학년도 1학기 캡스톤디자인 최종보고서를 제출합니다.

2025년 06월 12일

데 이 터 사 이 언 스 전 공

## 목 차

|                             |   |
|-----------------------------|---|
| 제 I 장 서론 .....              | 2 |
| 1 목적 및 필요성 .....            | 2 |
| 2 활용 방안 .....               | 2 |
| 제 II 장 분석 기획 .....          | 3 |
| 1 비즈니스 이해 및 범위 설정 .....     | 3 |
| 2 프로젝트 정의 및 계획 설정 .....     | 3 |
| 3 위험계획 수립 .....             | 3 |
| 제 III 장 데이터 준비 .....        | 4 |
| 1 필요 데이터 정의 .....           | 4 |
| 2 데이터 수집 및 전처리 .....        | 4 |
| 제 IV 장 데이터 분석 .....         | 5 |
| 1 감정라벨링 구축 .....            | 5 |
| 2 문제 해결 방법 모색 .....         | 5 |
| 3 감정 세분화 진행 .....           | 5 |
| 4 최종 전처리 진행 .....           | 6 |
| 5 NCF 모델 기반 추천 시스템 구현 ..... | 7 |
| 제 V 장 평가 및 전개 .....         | 8 |
| 1 과적합 발생 및 해결 .....         | 8 |
| 2 모델 성능 평가 .....            | 8 |
| 3 모델 개선 및 성능 향상 .....       | 9 |
| 4 성능 평가 방식 전환 .....         | 9 |

# I 서론

---

## 1. 목적 및 필요성

### 가. 목적

- ☐ 사용자의 감정 상태에 기반하여 보다 정확하고 개인화된 영화 추천 서비스 제공
- ☐ 기존의 단순 평점 중심 추천 시스템의 한계를 보완하여 서비스 질 향상

### 나. 필요성

- ☐ 영화 추천 시스템에서 사용자의 감정 상태 반영 필요성 증가
- ☐ 개인의 정서적 요구와 맥락을 반영한 서비스에 대한 수요 증가

## 2. 활용 방안

- ☐ OTT 서비스에서 개인화 추천 시스템으로 활용하여 만족도 및 서비스 이용률 증대
- ☐ 영화 제작 및 마케팅 단계에서 소비자 분석 도구로서 활용

## II 분석 기획

---

### 1. 비즈니스 이해 및 범위 설정

#### 가. 비즈니스 이해

- ☐ 사용자 맞춤형 영화 추천 서비스 시장에서 경쟁력 있는 서비스 구축

#### 나. 범위 설정

- ☐ Amazon 영화 리뷰 데이터를 이용한 감정 분석 및 영화 추천 시스템 개발

### 2. 프로젝트 정의 및 계획 설정

#### 가. 프로젝트 정의

1. 사용자 감정 상태 입력을 기반으로 맞춤 영화 추천 시스템 개발
2. 텍스트 리뷰 기반으로 사용자 감정 상태를 효과적으로 파악할 수 있는 감정 분류 진행
3. 감정 데이터를 정확히 추출하고 사용자의 현재 정서 상태를 반영하는 영화 추천 시스템 설계

#### 나. 계획 설정

1. 데이터 수집 및 전처리
2. 감정 라벨링 구축
3. 추천 시스템 개발
4. 시스템 구현 및 평가

### 3. 위험계획 수립

- ☐ 한정된 컴퓨팅 자원으로 인한 어려움 발생
- ☐ 텍스트 기반 감정 라벨링 정확도가 기대 수준 이하일 가능성 존재
- ☐ 데이터 불균형 문제 발생: 한 가지 혹은 두 가지 감정으로 편향 발생 가능성 존재
- ☐ 감정 라벨링 방식에 대한 학습 및 고찰이 필요

### III 데이터 준비

---

#### 1. 필요 데이터 정의

가. 영화 리뷰 데이터(텍스트, 평점, 영화 제목 등)

나. 감정 라벨링을 위한 사전학습 모델 또는 감정 어휘 사전

다. 시스템 성능을 높이기 위한 컬럼을 추가할 때 필요한 IMDB 데이터 등의 보조 데이터

#### 2. 데이터 수집 및 전처리

가. 데이터 수집

☐ Amazon Movies & TV 리뷰 데이터셋

☐ 영화 추천 시스템 데이터의 대표적인 MovieLens 데이터셋

☐ 장르와 개봉연도 등의 컬럼을 추가해줄 IMDB 메타 데이터

나. 데이터 전처리

1. Amazon 데이터와 MovieLens 데이터 통합 시도

☐ 두 데이터를 통합하기 위해 IMDBPy 라이브러리를 활용하여 Amazon 데이터의 title 컬럼에서 IMDB ID 추출

☐ 하지만 두 데이터의 공통된 IMDB ID가 5,469개로 굉장히 희소하기에 회의를 통해 Amazon 데이터만으로 진행하기로 결정

☐ 위에서 추출한 IMDB ID를 활용하여 추가로 장르, 연도 컬럼 생성

2. Amazon 데이터 전처리

☐ 불필요한 컬럼 및 결측값 제거

☐ nltk를 활용하여 토큰화, 소문자 통일, 불용어 제거, 표제어 추출 등의 텍스트 전처리 진행

☐ TF-IDF 벡터화 적용(사용 X)

## IV 데이터 분석

---

### 1. 감정 라벨링 구축

가. 모델 ‘bhadresh-savani/distilbert-base-uncased-emotion’ 활용

- ☐ Transformer 인코더(지식 증류 DistilBERT) 기반
- ☐ 공개 파인튜닝 모델 중 감정 분류 F1 93%로 성능 우수
- ☐ 경량, 고속이며 연구, 상업 등 사용이 자유로움

나. 감정 라벨링 구축 결과, 즐거움이 약 88%로 편향 문제 발생

- ☐ 모델이 트위터로 학습 되었는데, 원본 데이터가 불균형한 것을 확인
- ☐ 트위터의 문장과 영화 리뷰라는 도메인 시프트 때문에 모델이 감정을 즐거움으로 과대 해석한 것으로 예상됨.

### 2. 문제 해결 방법 모색

가. 샘플링

- ☐ 오버 샘플링
  - 소수 클래스의 데이터 수를 증가시켜 데이터셋의 균형을 맞춤
  - 단순 복제: 소수 클래스에 속하는 리뷰를 단순히 복제하여 데이터 수를 늘림
  - 텍스트 SMOTE: 단어 임베딩을 활용하여 소수 클래스의 기존 리뷰와 유사한 새로운 리뷰를 생성
- ☐ 언더 샘플링
  - 다수 클래스의 데이터 수를 감소시켜 데이터셋의 균형을 맞춤
  - 랜덤 언더샘플링: 다수 클래스에 속하는 리뷰를 무작위로 제거함

나. 다른 모델 탐색

### 3. 감정 세분화 진행

가. 샘플링 기법의 단점

- ☐ 샘플링 편향
  - 모집단의 분포가 그대로 반영되지 않으면 성능이 과대, 과소 추정될 수 있음
  - 특정 집단, 패턴이 소외될 위험이 존재

☐ 데이터 누수

- Oversampling 등을 분할 전에 수행하면 복제 및 합성된 데이터가 테스트셋에 섞여 과도한 점수를 유발

☐ 성능지표 무의미

- 편향된 샘플에서 계산한 성능은 실제 서비스에서 재현되지 않을 수 있음

나. ‘즐거움’ 감정 세분화 진행

- ☐ 기존 단일 최상위 감정 예측 방식에서 Top-3개 감정을 예측하고 신뢰도 계산
- ☐ 편향된 ‘즐거움’ 감정을 키워드, 장르, 신뢰도 임계값 기반의 재분류로 보정
- ☐ ‘즐거움’을 유머러스, 감탄의 세부 감정으로 세분화 진행
- ☐ 결과적으로 ‘즐거움’ 감정 비율이 기존 88%에서 약 40%로 감소

## 4. 최종 전처리

가. 중복 행 제거

- ☐ 중복된 user\_id, item\_id 쌍 제거 (총 3587개)

나. 장르 인코딩

- ☐ 26가지 장르 원-핫 인코딩 수행

다. 감정 인코딩

- ☐ 9가지 감정 원-핫 인코딩 수행

라. 제목 임베딩

- ☐ 영화 제목을 단어 단위로 분해한 후 Word2Vec를 사용해 유의미한 숫자 벡터로 변환(100개 컬럼 추가)

마. item\_id, user\_id 인코딩

- ☐ 둘 다 레이블 인코딩 수행

바. year, rating 컬럼 스케일링

- ☐ 수치형 컬럼에 min-max 스케일링 수행

사. 임베딩한 제목 정규화

아. 원본 텍스트 감정, 텍스트 리뷰 전처리 결과 등의 불필요한 컬럼 제거



## 5. NCF 모델 기반 추천 시스템 구현

가. 감정 필터링 함수 `filter_by emotion`

- ☐ 추출한 감정 맵핑 이후 영화 필터링

나. 데이터 분할 함수 `split_data`

- ☐ 같은 사용자의 데이터가 `train`과 `test`에 모두 포함되면 과적합될 위험이 있기 때문에 사용자 단위로 중복 없이 분할

다. NCF 모델 생성 함수 `create_ncf_model`

- ☐ 사용자, 아이템에 대한 임베딩 등의 `feature`를 입력으로 받는 신경망 구조 정의
- ☐ 사용자가 특정 영화를 좋아할지, 싫어할지 이진 분류 진행

라. 모델 훈련 함수 `train_model`

- ☐ 평점 3.5 이상이면 1, 미만이면 0으로 변환하여 모델 훈련

마. 영화 추천 함수 `recommend_movies`

- ☐ 감정 상태에 맞는 영화를 필터링한 후, 모델을 사용하여 사용자의 선호도를 예측
- ☐ 선호도가 높은 순으로 상위 N개의 영화 추천

바. 모델 평가 함수 `evaluate_model`

- ☐ 분할한 `test` 데이터를 활용하여 모델의 성능 평가
- ☐ 일단 `accuracy` 만으로 성능 지표 설정

사. 전체 시스템 실행 함수 `run_emotion_based_recommendation_system`

- ☐ 위의 전체 파이프라인 실행

아. 메인 시스템 함수 `get_recommendation_for_emotion`

- ☐ 특정 감정에 대한 추천을 출력하는 메인 코드

## V 평가 및 전개

---

### 1. 과적합 발생 및 해결

가. 모델 학습 Epoch 2부터 accuracy 1.0(100%)로, 심각한 과적합이 발생

- ☐ Target의 불균형, 데이터 누수, 데이터 분할의 문제 등을 원인으로 추정

나. 과적합 현상 해결

- ☐ 데이터 분할 개선
  - 사용자와 아이템 상호작용 기준으로 분할하여 특정 상호작용이 한 세트에만 포함되도록 수정
- ☐ Target 변수 재정의
  - 데이터의 평점 분포를 확인하고 중앙값 기준으로 설정
- ☐ 모델 복잡도 감소 및 정규화 강화
  - 모델 레이어 크기 축소
  - L2 정규화 추가
  - 학습률 감소
- ☐ 조기 종료 및 학습률 스케줄링
  - 과적합 방지를 위한 early stopping 추가
- ☐ 클래스 불균형 처리
  - 클래스 가중치를 계산하여 학습 시 적용
  - 소수 클래스에 더 높은 가중치 부여

### 2. 모델 성능 평가

가. 성능 평가 기준

- ☐ 평점의 중앙값을 임계값으로 활용해 좋아요 및 싫어요로 이진 분류
- ☐ 절대적인 평점 값이 아니라 데이터셋 내 모든 평점의 상대적인 위치를 기준으로 활용
- ☐ 평자 지표로 Accuracy, Precision, Recall, F-1 score 설정

#### 나. 성능 평가 정리

- ☐ Accuracy: 0.6812
- ☐ Precision: 0.6867
- ☐ Recall: 0.6183
- ☐ F-1 score: 0.6507

### 3. 모델 개선 및 성능 향상

#### 가. 모델 개선 사항 요약

- ☐ 임베딩 크기
  - 32차원에서 64차원으로 증대
- ☐ hidden unit 크기
  - [128, 64]에서 [256, 128, 64] 로 증대
- ☐ 임계값 (Threshold)
  - 중위값 고정에서 자동 최적화 방식으로 전환
- ☐ 하이퍼파라미터
  - learning\_rate, batch\_size 등 고정 설정에서 자동 튜닝 방식으로 전환

#### 나. 성능 향상 요약

- ☐ Accuracy: 0.6812 → 0.7088 (4.05%↑)
- ☐ Precision: 0.6867 → 0.8435 (22.83%↑)
- ☐ Recall: 0.6183 → 0.7306 (18.16%↑)
- ☐ F-1 score: 0.6507 → 0.7830 (20.33%↑)

※ 상대 향상률로 계산한 값입니다.

### 4. 성능 평가 방식 전환

#### 가. 전환된 평가 방식

- ☐ 기존의 일반적인 이진 분류 지표에서 추천 시스템에 특화된 평가 지표로 전환
  - Precision@K: 상위 K개 추천 중 사용자가 선호할 확률
  - Recall@K: 사용자 선호 영화 중 상위 10개에 포함된 비율
  - NDCG@K: 순서를 고려한 추천 품질 점수
  - Hit Rate@K: 상위 10개 중 최소 1개 만족하는 사용자의 비율

나. 전환된 평가 방식 성능 요약

☐ Precision@10: 0.2833

☐ Recall@10: 0.6250

☐ NDCG@10: 0.5206

☐ Hit Rate@10: 0.667

## 참 고 문 헌

1. Amazon Movies & TV Dataset (<https://nijianmo.github.io/amazon/index.html>)
2. HuggingFace Model (<https://huggingface.co/bhadresh-savani/distilbert-base-uncased-emotion>)
3. NLTK Documentation (<https://www.nltk.org/>)
4. MovieLens Dataset (<https://grouplens.org/datasets/movielens/>)
5. 권철민, 『파이썬 머신러닝 완벽 가이드』, 위키북스, 2024